

Projeto Final - IESTI01: Identificação de Pássaros por Meio do Canto

Autores:

Arthur Gonçalves Marton -2023009270

Felipe Rodrigues Malizia - 2023001414

Vicenzo Cenni - 2023001915

1. Resumo

Este relatório apresenta um projeto focado na identificação de pássaros através da análise de seus cantos, utilizando a tecnologia TinyML. Foi utilizado um dataset disponibilizado na internet, em [!\[\]\(e3f8612927870f2e0f9f5989e6dd3064_img.jpg\) Sound Of 114 Species Of Birds Till 2022 !\[\]\(a86c7d1c9cb81c81614634a31267440d_img.jpg\)](#). O sistema empregou um microfone para a captação do silêncio. Os dados foram, então, processados e convertidos em espectrogramas para extração de características. A abordagem de machine learning embarcado permitiu a identificação local sem dependência de conexão com a internet, tornando a solução eficiente para áreas remotas e contribuindo para o monitoramento ecológico de baixo custo. Foram utilizadas amostras de 7 tipos diferentes de pássaros e silêncio, processadas no Edge Impulse, e o modelo obteve uma acurácia de teste de 87,65%.

2. Introdução

A identificação de espécies é crucial para estudos de biodiversidade e monitoramento ecológico. Tendo isso em vista, métodos tradicionais, sem a utilização de tecnologias mais modernas de classificação, podem ser trabalhosos e exigem a presença de especialistas. Outra abordagem possível, que reduz a necessidade do especialista presente a todo momento, é o uso de câmeras nas áreas para a visualização de um indivíduo no ambiente. Entretanto, para o caso especial de classificação de pássaros, um recurso que necessita de muito menos esforço, tanto humano quanto computacional, é a classificação através dos sons emitidos por cada espécie de ave.

O reconhecimento através do som pode ser mais eficiente do que o uso de câmeras ou especialistas por poder cobrir uma grande área em 360 graus sem a necessidade do trabalho inicial cauteloso de se encontrar uma certa área onde o indivíduo passará. Por exemplo, para se encontrar um possível pássaro que está habitando um ambiente é preciso primeiro que um especialista venha ao local e estipule onde exatamente o espécime pegaria comida ou habitaria, para então se posicionar uma câmera que capture aquela região específica. Já no caso do som, é necessário apenas uma pequena aproximação da localização para se posicionar um equipamento que poderá ouvir o canto e estipular se aquele indivíduo faz ou não parte da espécie estipulada.

Além disso, com o avanço da tecnologia de Machine Learning, especialmente o TinyML, tornou-se viável desenvolver soluções automatizadas e de baixo custo para resolver problemas de classificação sem a necessidade de um alto custo computacional ou de estar conectado de forma integral a uma rede de computadores para o cálculo

responsável por classificar. Dessa forma, através da tecnologia TinyML, é possível se criar uma rede neural e utilizá-la em lugares mais remotos, onde sinais de rede sem fio em tempo integral ou cabos conectores são inviáveis sem que seja preciso um alto investimento inicial e de manutenção da infraestrutura de rede.

Com isto em mente, este projeto visou criar uma rede neural através do Edge Impulse para classificar 7 diferentes tipos de pássaros por seus diferentes cantos e sons característicos e então, com o sucesso do modelo, realizar a implementação do mesmo em um Arduino Nano 33 BLE, um hardware embarcado e embutido com um microfone.

3. Metodologia


A metodologia do projeto abrangeu as seguintes etapas:

- **Hardware Utilizado:**

- Arduino Tiny Machine Learning Kit AKX00028
- Arduino Nano 33 BLE Sense
- Shield Arduino Tiny Machine Learning
 - Um microfone, utilizando o Arduino Nano 33 BLE Sense (com microfone integrado), foi empregado para a captação de sons ambientais.


- **Coleta de Dados:**

- Os dados foram obtidos do dataset "sound-of-114-species-of-birds-till-2022", que pode ser encontrado de maneira pública no Kagle.
- Foram escolhidas amostras referentes a 7 tipos diferentes de pássaros: aracuã-de-barriga-branca, inhambu-relógio, jacupemba, peru-do-mato-de-colar-marrom, aracuã-de-sobrancelhas, perdigão e ema; além disso, foram coletadas amostras referentes ao som de silêncio.
- Tentou-se utilizar uma quantidade similar de tempo de dados entre os animais de aproximadamente um minuto e meio, entretanto, alguns possuíam uma quantidade muito inferior aos outros, o que acabou deixando esses com uma menor variedade.
- A divisão entre dados de treino e dados de teste foi feita na proporção 80/20. Como mostra a imagem abaixo:



- **Pré-processamento:**

- Os arquivos de áudio captados foram transformados em imagens (espectrogramas).
- Foram aplicados filtros para extrair características essenciais das imagens.
- Para a criação do impulso através do Edge Impulse, utilizou-se um bloco de processamentos de espectrogramas e um bloco de aprendizado do tipo classificador. As amostras foram divididas em janelas de 750 ms com avanço (stride) de 375 ms, além de possuírem frequência de 16000 Hz.
- Para a geração das features, realizou-se a calibragem dos parâmetros através do software que retornou os valores ideais a serem utilizados no espectrograma e na normalização dos dados. Os resultados obtidos podem ser vistos a seguir:



- **Design do Modelo:**

- Foi utilizada uma Rede Neural Convolutacional 2D (CNN 2D).
- O modelo foi otimizado utilizando o EON Compiler do próprio Edge Impulse.
- Após uma extensa quantidade de tentativas e erros, chegou-se à conclusão de que para atingir uma boa acurácia com o menor erro possível, deveriam ser feitos 150 ciclos de treinamento, sem a realização de um *data augmentation*. Nos testes, a realização do *data augmentation* passou a diminuir a acurácia do projeto.

- **Inferência no Sistema (Deploy):**

- O modelo treinado foi implantado no Arduino Nano 33 BLE Sense para realizar a identificação de pássaros localmente, sem a necessidade de conexão com a internet.

4. Resultados

Com o treinamento realizado, obteve-se uma acurácia no treino de 85,6% com uma perda de 0,35. Após o teste do modelo, obteve-se uma acurácia de 87.65%. A matriz de confusão abaixo mostra os resultados obtidos após o teste do modelo:

	ARACUABA	ARACUASO	EMA	INHAMBU	JACU	PERDIGAO	PERU	SILENCIO	UNCERTAIN
ARACUABA	66.7%	0%	5.6%	11.1%	0%	0%	0%	0%	16.7%
ARACUASO	0%	72.2%	5.6%	5.6%	0%	0%	0%	0%	16.7%
EMA	0%	0%	93.8%	0%	0%	0%	0%	0%	6.3%
INHAMBU	0%	0%	0%	100%	0%	0%	0%	0%	0%
JACU	4.2%	0%	0%	0%	70.8%	4.2%	0%	12.5%	8.3%
PERDIGAO	0%	0%	0%	0%	0%	93.8%	0%	0%	6.3%
PERU	0%	0%	0%	0%	0%	0%	100%	0%	0%
SILENCIO	0%	0%	0%	0%	0%	0%	0%	100%	0%
F1 SCORE	0.77	0.84	0.91	0.95	0.83	0.94	1.00	0.90	

Os testes no Arduino também se mostraram satisfatórios, com o sistema conseguindo identificar corretamente a maioria dos cantos apresentados, apenas com uma dificuldade maior no reconhecimento do Inhambu.

5. Conclusão

Este projeto demonstrou o potencial do TinyML na criação de soluções inovadoras para desafios ambientais. O grupo teve grande dificuldade na filtragem dos dados; a base de dados utilizada possuía mais de 2000 amostras de áudio, muitas delas classificadas erroneamente. Além disso, a frequência dos dados obtidos por vezes ultrapassava os 16 kHz, limite máximo do microfone do Arduino, o que fez com que tivessem de ser manipulados para poderem ser classificados corretamente, além de terem que ter sido convertidos todos de MP3 para WAV para serem aceitos no Edge Impulse. Apesar desses desafios, a implementação bem-sucedida de uma Rede Neural embarcada no Arduino Nano 33 BLE Sense permitiu a classificação autônoma de pássaros por meio de seus cantos, fornecendo uma ferramenta valiosa para a conservação e pesquisa da vida selvagem. A baixa quantidade de dados foi uma preocupação inicial, mas a decisão de não utilizar *data augmentation* baseou-se nos resultados empíricos obtidos durante os testes, que indicaram uma diminuição da acurácia com sua aplicação.