

Relatório Projeto Final

Nome: Rafael Belchior Ferreira

Número: 2022006194

1. Objetivo

Desenvolver um sistema embarcado utilizando TinyML para classificação de sons ambientes, como latidos de cachorro e sirenes, com foco em aplicações de monitoramento inteligente e segurança residencial.

2. Descrição Longa do Projeto

Este projeto visa criar um sistema de classificação de sons em tempo real, totalmente embarcado no microcontrolador. A solução foi desenvolvida para operar de forma autônoma, sem necessidade de conexão com a nuvem, garantindo baixa latência, privacidade e baixo consumo de energia. Utilizando a plataforma Edge Impulse, um modelo de aprendizado de máquina foi treinado para diferenciar sons específicos do ambiente. As principais aplicações para um sistema como este incluem o monitoramento de segurança (ex: detectar um latido de cachorro dentro de casa), automação residencial (ex: acionar uma luz ao ouvir um som específico) e monitoramento ambiental. O resultado da classificação é sinalizado em tempo real por meio dos LEDs integrados na placa.

3. Referências e Fontes de Inspiração

- Edge Impulse: Os exemplos e a documentação da plataforma foram a base para o desenvolvimento do pipeline de áudio.
- ESC-50 Dataset: O projeto utilizou um subconjunto do dataset público "ESC-50: Dataset for Environmental Sound Classification" para obter as amostras de áudio de latidos e sirenes.

4. Detalhes Técnicos do Projeto

4.1. Diagrama de Blocos

[Entrada de Áudio (Microfone)] -> [Pré-processamento (MFE)] -> [Modelo CNN (Inferência)] -> [Saída da Classificação] -> [Controle de LEDs]

4.2. Hardware Utilizado

- Microcontrolador: Arduino Nano 33 BLE Sense.
- Sensores: Microfone integrado na placa.
- Atuadores: LEDs RGB integrados na placa para sinalização visual do resultado.

4.3. Coleta de Dados

- Classes: Foram definidas 3 classes: dog (latido), sirene (sirene) e ruído (ruído de fundo).
- Fonte: Foram utilizadas 20 amostras de áudio para as classes dog e sirene do dataset público ESC-50. A classe ruído foi criada com 30 amostras de 1 segundo de ruído ambiente, capturadas com o próprio Arduino.

4.4. Pré-processamento

- Janelamento: O áudio foi segmentado em janelas de 1000 ms.
- Extração de Características: Foi utilizado o bloco Audio (MFE) do Edge Impulse.

4.5. Design do Modelo

- Arquitetura: Foi utilizada uma Rede Neural de Classificação (Keras) fornecida pelo Edge Impulse.
- Treinamento: O modelo foi treinado na plataforma Edge Impulse por aproximadamente 100 épocas, com uma taxa de aprendizado padrão de 0.005.

4.6. Otimizações

- Quantização: O modelo foi convertido para o formato TensorFlow Lite for Microcontrollers utilizando quantização completa para inteiros de 8 bits.

4.7. Inferência no Sistema (Deploy)

- O modelo otimizado foi exportado do Edge Impulse como uma biblioteca para Arduino.
- Essa biblioteca foi importada na Arduino IDE e o código de exemplo `nano_ble33_sense_microphone` foi modificado para:
 1. Executar o classificador a cada 2 segundos.
 2. Analisar o resultado da inferência.
 3. Acionar os LEDs de acordo com a classe detectada com maior probabilidade (Vermelho para dog, Azul para sirene).

5. Problemas Encontrados e Soluções

O principal obstáculo encontrado foi um erro de configuração durante a geração de features na plataforma Edge Impulse (`common.errors.ConfigurationError: At least one row of the mel filterbank contains all zeros`). O erro indicava que a combinação dos parâmetros do MFE era inválida. A solução foi seguir a sugestão do próprio log de erro:

- Solução: O parâmetro "Filter number" nas configurações do MFE foi reduzido de 40 para 32, o que resolveu o problema e permitiu a geração correta das características de áudio.

8. Questões em Aberto e Próximos Passos

Embora o protótipo funcional tenha sido concluído com sucesso, algumas questões permanecem como oportunidades para trabalhos futuros:

- Escalabilidade: Como a acurácia do modelo se comportaria ao adicionar mais classes de sons ambientes (ex: buzina, chuva, vidro quebrando)?
- Robustez: Qual o impacto de diferentes tipos de ruído de fundo na performance do classificador? Seria necessário um dataset de ruído mais abrangente?
- Otimização de Energia: Seria possível implementar um ciclo de duty-cycling (ligar e desligar o microfone) para reduzir ainda mais o consumo de energia sem perder detecções importantes?

Link do projeto no Edge Impulse: <https://studio.edgeimpulse.com/public/733623/live>

Link do vídeo de funcionamento do projeto:

<https://drive.google.com/file/d/1HiAdHhA5F7TQE74dnj69UmBpJIGlh98F/view?usp=sharing>